Universidad Tecnológica Nacional

Facultad Regional Buenos Aires · Centro de e-Learning

Diplomatura en Ciencia de Datos y Análisis Avanzado

Módulo 10 — Proyecto Final Integrador

Evaluación de la tasa ajustada por riesgo como indicador de desempeño hospitalario

Aplicación al análisis de sepsis posoperatoria en hospitales de California · 2019–2023

Autor: Lisandro Chiavassa

Fecha: octubre de 2026

Pregunta de evaluación

¿La tasa ajustada permite comparar hospitales muy distintos de manera suficientemente justa como para decidir dónde auditar?

Respuesta breve: en general sí, porque el volumen no la explica; pero en bajo volumen la calificación anual pierde información.

1.470 observaciones hospital-año

312 hospitales de California

5 años serie 2019–2023 (COVID-19)

Notebook (Google Colab): [agregar enlace] · **Repositorio (GitHub):** [agregar enlace]

Datos: HCAI · California Open Data · licencia CC BY

Resumen ejecutivo

Si la tasa realmente ajusta por riesgo, tendría que ser independiente del tamaño del hospital.

Problema. No resulta equivalente comparar los casos brutos de un hospital con pacientes de mayor complejidad con los de otro de menor complejidad. La tasa ajustada intenta corregir esa diferencia. La pregunta es si alcanza para orientar decisiones de auditoría y control de calidad hospitalaria.

Qué hice. Estudié tres dimensiones simultáneas: geografía, tiempo y desempeño. Para distinguir un episodio aislado de un patrón repetido construí el índice de persistencia, y puse a prueba la relación volumen–tasa fuera de la muestra.

Impacto. Una lectura única del indicador se transforma en una estrategia de auditoría más contextual: de 65 calificaciones Below Average a 5 hospitales con un patrón repetido.

Resultados clave

$R^2 \approx 0$

El volumen, utilizado de manera aislada, no predice de forma confiable la tasa (R^2 en validación cruzada de 0,001).

0,588

Balanced accuracy CV del modelo elegido (azar: 0,333). F1 macro en test de 0,608; ROC-AUC de 0,75.

3,8 ×

Un denominador pequeño produce mayor volatilidad: más dispersión en bajo volumen.

65 → 5

De la foto anual a la película: calificaciones Below frente a patrones crónicos.

Definición del problema y relevancia

Comparar hospitales exige corregir diferencias de riesgo; la pregunta es si esa corrección se sostiene entre hospitales muy distintos.

Contexto. La sepsis posoperatoria es una complicación grave y en parte prevenible. HCAI publica su tasa ajustada por riesgo (metodología AHRQ) y califica a cada hospital como Above, Average o Below Average.

Hospital A
menor complejidad

Tasa ajustada
nivela el campo de juego

Hospital B
mayor complejidad

Por qué importa. La calificación orienta auditorías, contratos y reputación pública. Leerla mal cuesta recursos de auditoría y puede estigmatizar a un hospital sin evidencia.

Objetivo medible y KPI

1. Medir fuera de muestra cuánto explica el volumen la tasa. **KPI: R^2 en validación cruzada.**
2. Evaluar si tasa y persistencia reconocen el tamaño. **KPI: balanced accuracy vs. 0,333.**
3. Proponer una regla de auditoría. **KPI: auditorías vs. regla anual (65).**

Hipótesis y restricciones

H1 la pandemia redujo el volumen electivo: confirmada (−24,4 %).

H2 la tasa cambió con el denominador: no confirmada.

Límites: sin variables de case-mix; período atípico; 312 hospitales.

Datos y metodología

Dataset público y real: 1.475 registros, 10 variables y ningún duplicado; los faltantes estaban en el agregado estatal.

Variable clave	Rol en el análisis
Postoperative Sepsis Cases	Numerador: casos
Elective Surgical Discharges	Denominador: volumen
Risk-adjusted Sepsis Rate	Variable central
Performance Rating	Ordinal: Above · Average · Below
Year · County · OSHPDID	Tiempo e identificación
Latitude · Longitude	Geografía

Calidad detectada	Decisión tomada
Nulos solo en las 5 filas STATEWIDE	Excluirlas: 1.470 filas, 0 nulos
Longitud y latitud como texto	Conversión a numérico
Outliers IQR: 138 · 106 · 64	Se conservan; Spearman y log
35 hospitales con menos de 5 años	Agregación por hospital

Metodología CRISP-DM

1. Negocio
Pregunta y KPI

2. Datos
EDA y calidad

3. Preparación
Persistencia, segmentos, log

4. Modelado
Regresiones y 6 clasificadores

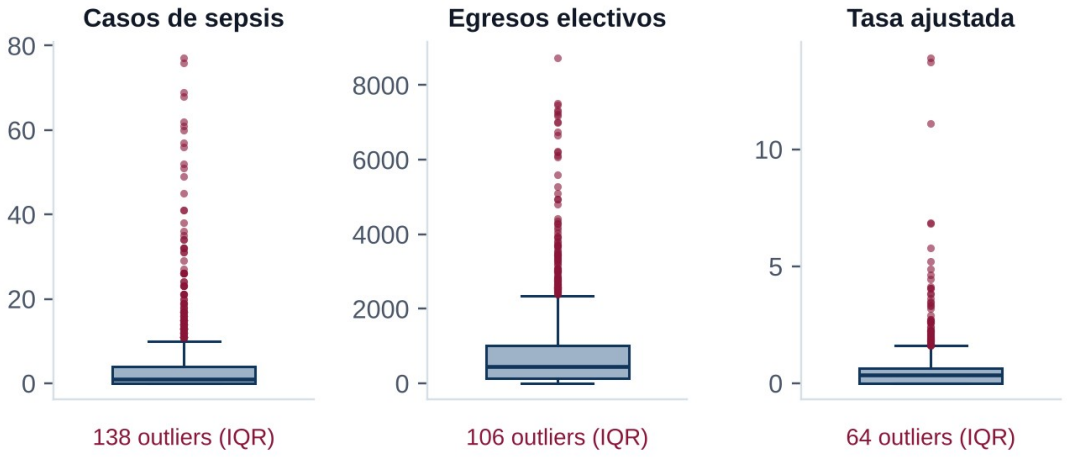
5. Evaluación
CV 5 folds + test 80/20

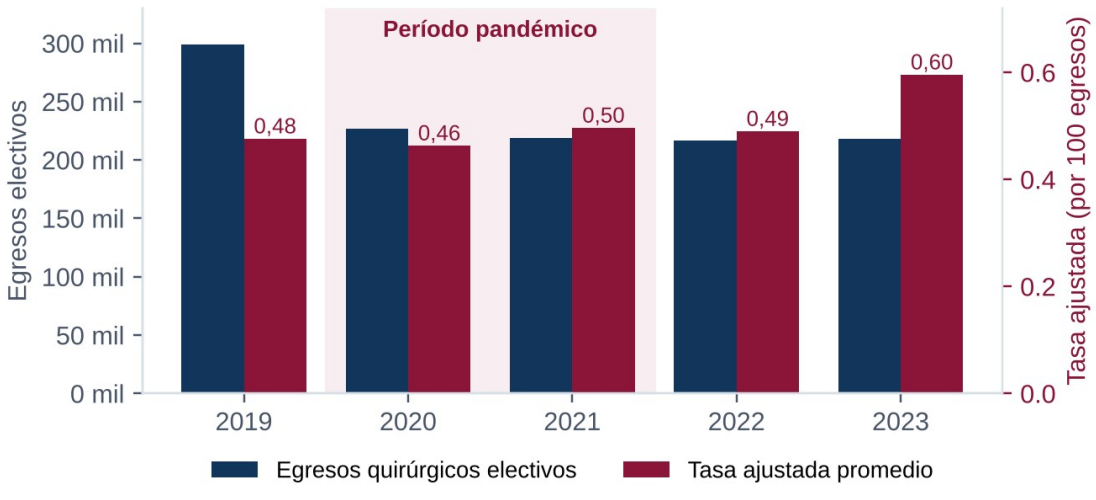
6. Despliegue
Modelo de auditoría

HCAI · California Open Data · recurso AHRQ Postoperative Sepsis Rates 2019–2023 · CC BY

Conclusiones del EDA: heterogeneidad, pandemia y una señal moderada

Antes de modelar hubo que aceptar que el sistema no es homogéneo y que el período es atípico.





Pocos hospitales concentran muchos casos; los outliers se conservan.

El volumen cayó 24,4 % en 2020; la tasa no cayó en paralelo.

0,787
Volumen ↔ casos

0,736
Casos ↔ tasa

0,355
Volumen ↔ tasa

ρ de Spearman ($p < 0{,}001$): robusto a outliers, sin suponer linealidad. La asociación volumen ↔ tasa es moderada: había que validarla a nivel hospital.

Ingeniería de variables: el índice de persistencia

De la foto anual a la película: cuántos años repitió cada hospital su calificación en 2019–2023.

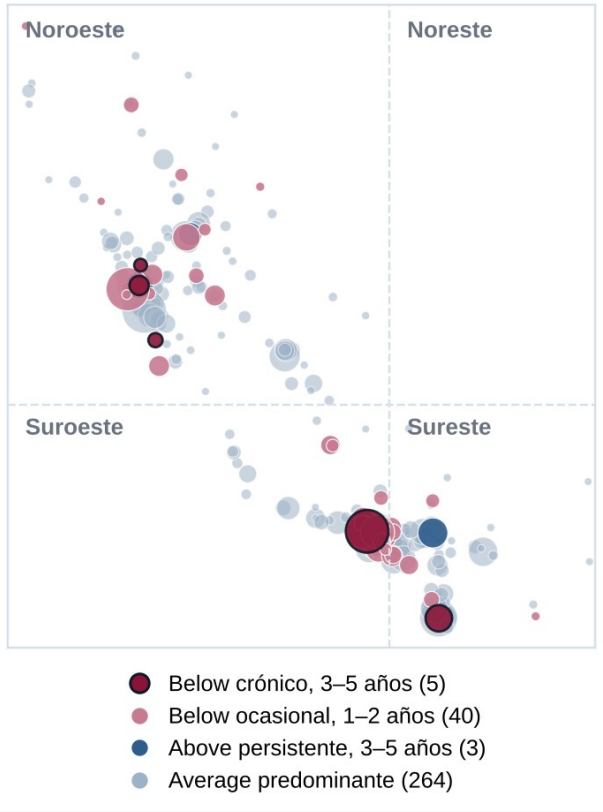
Cuenta los años Below y Above Average de cada hospital. No estaba en el dataset: integra hospital, tiempo y desempeño.

264
Average predominante

40
Below ocasional · 1–2 años

5
Below crónico · 3–5 años

3
Above persistente · 3–5 años



Lectura geográfica

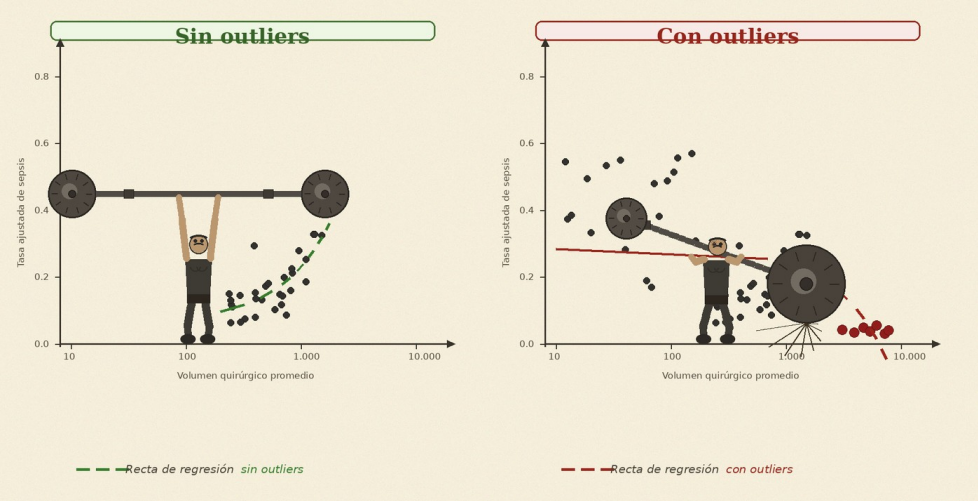
Hospitales con algún año Below: 40 % noroeste, 40 % suroeste, 20 % sureste. De los 5 crónicos, 3 están en el noroeste.

Foco Cedars-Sinai

Below crónico, 6.756 egresos/año. En 12 km: 5,4 % de los hospitales y 14,9 % de los casos. Señal, no causa.

Modelado I · Regresión: el volumen no explica la tasa ajustada

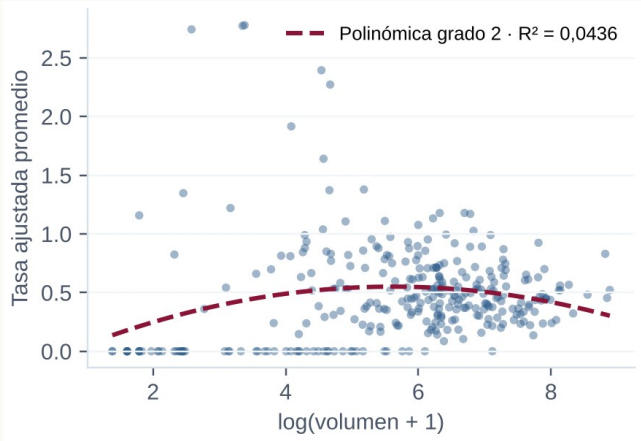
Cuatro modelos validados fuera de muestra; ninguno supera de forma relevante a predecir siempre la media.



El peso de los extremos. Una sola recta carga con hospitales muy distintos: los extremos la desbalancean y queda casi plana ($R^2 \approx 0$; $p = 0{,}90$), con residuos heterocedásticos.

Por segmento: R^2 de 0,018 · 0,012 · 0,037; $p > 0{,}14$ en los tres.

Modelo (5 folds)	R^2 muestra	R^2 CV	MAE CV
Baseline: media	0,000	−0,034	0,297
Lineal · volumen	0,000	−0,039	0,297
Lineal · log(volumen)	0,011	−0,023	0,294
Polinómica g2 · log(vol.)	**0,044**	**0,001**	**0,285**



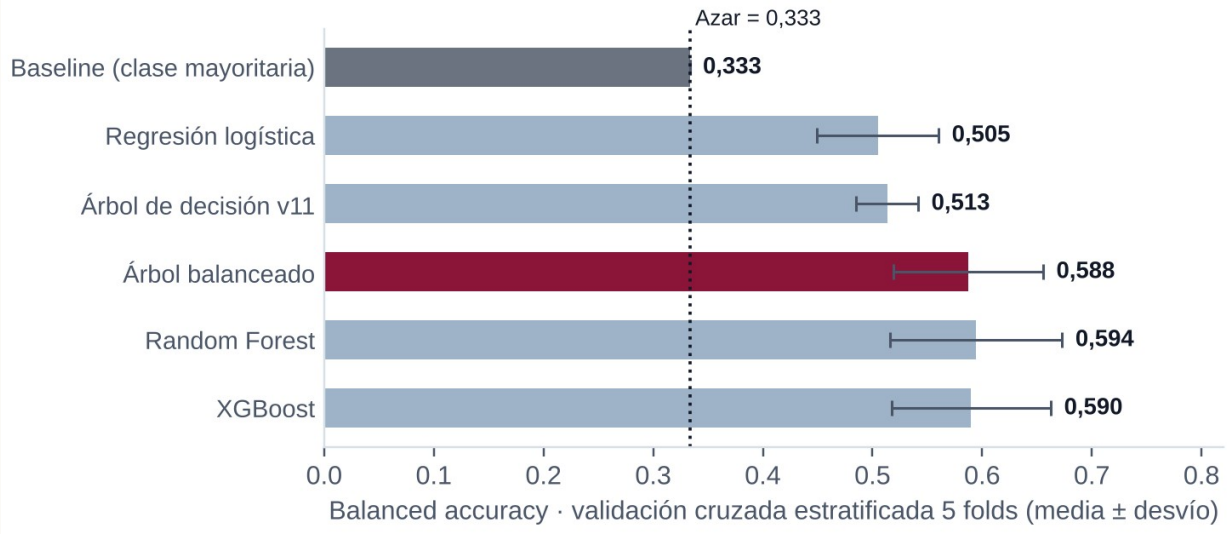
La “cúpula” ($R^2 = 0{,}0436$) parecía sostenerse en el corte 70/30; el K-fold la descartó: $R^2 = 0{,}0012$.

Validar evitó convertir una imagen convincente en una conclusión falsa.

Modelado II · Clasificación: seis modelos con el mismo protocolo

¿La tasa y la persistencia permiten reconocer el tamaño del hospital? Si lo lograran, el indicador estaría contaminado por el volumen.

1. **Datos:** 312 hospitales, una fila por hospital.
2. **Predictores:** tasa + persistencia; el volumen no entra porque define la clase.
3. **Objetivo:** segmento bajo · medio · alto (106 · 175 · 31).
4. **Validación:** CV estratificada de 5 folds + test 80/20 (63 hospitales).
5. **Selección:** a menos de 1 desvío del mejor hay empate; gana el más interpretable.



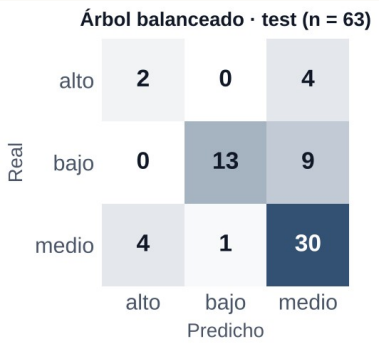
Tres modelos empatan arriba (0,588–0,594). **Se elige el árbol balanceado:** rinde igual y se lee como reglas.

Evaluación · Métricas comparadas y modelo elegido

El árbol balanceado logra el mejor F1 macro en test y es el único de los empatados que se lee como reglas.

Modelo	BA CV	F1 CV	AUC CV	Acc. test	Prec. test	Rec. test	F1 test	AUC test
Baseline (mayoritaria)	0,333	0,240	0,500	0,556	0,185	0,333	0,238	0,500
Regresión logística	0,505	0,373	0,593	0,476	0,467	0,502	0,413	0,638
Árbol v11	0,513	0,501	0,756	0,746	0,541	0,521	0,511	0,750
Árbol balanceado (elegido)	**0,588**	**0,591**	**0,744**	**0,714**	**0,653**	**0,594**	**0,608**	**0,750**
Random Forest	0,594	0,539	0,787	0,587	0,552	0,546	0,526	0,823
XGBoost	0,590	0,573	0,780	0,667	0,549	0,547	0,546	0,784

BA: balanced accuracy · métricas macro · AUC uno-contra-el-resto · CV 5 folds sobre 312 hospitales · test de 63 hospitales



Clase	Prec.	Recall	F1	AUC
Alto	0,333	0,333	0,333	0,713
Bajo	0,929	0,591	0,722	0,814
Medio	0,698	0,857	0,769	0,722

El árbol v11 tenía más accuracy (0,746), pero nunca detectaba el segmento alto.

Reglas del árbol elegido

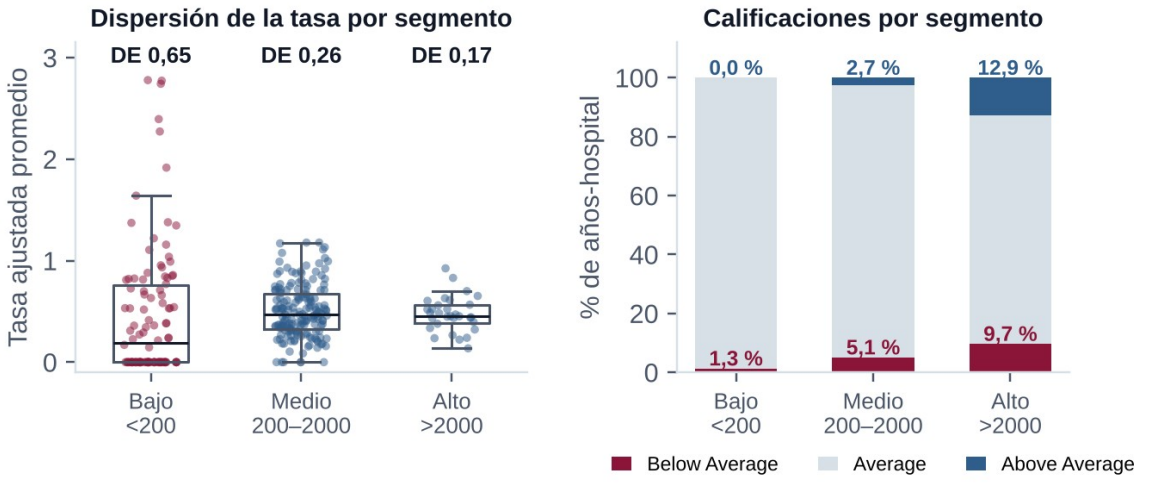
tasa ≤ 0,04 o > 1,20 → **bajo**

algún año Above y tasa ≤ 0,47 → **alto**

resto → **medio** · peso: tasa 72 %, Above 28 %

Impacto en el negocio · Un modelo de auditoría segmentado

Las reglas del árbol muestran la firma del denominador pequeño: el riesgo no es el tamaño, sino la falta de información.



65
calificaciones Below (regla anual)

45
hospitales distintos

5
crónicos: auditoría en profundidad

Segmento	Peso	Acción propuesta
Bajo · 106	2,7 % de casos	Tasa trienal
Medio · 175	48,3 % de casos	Rating + persistencia
Alto · 31	49,0 % de casos	Sumar complejidad

En bajo volumen, el **75,6 %** de los años tiene tasa 0, y las 11 tasas mayores a 1,20 son de hospitales chicos.

Casi nunca salen de Average: para ellos, “Average” puede significar “sin evidencia”.

−92 % de auditorías en profundidad. Ahorro = 60 × costo de una auditoría in situ (lo fija la institución). Los 40 ocasionales pasan a seguimiento.

Riesgos, limitaciones, ética y privacidad

Lo que estos datos permiten afirmar, lo que no, y cómo se mitigó.

Riesgos y limitaciones

- Sin variables de case-mix: no se separa complejidad de calidad.
- Serie atípica: el volumen cayó 24,4 % en 2020.
- Solo 31 hospitales de alto volumen (6 en test).
- Cortes 200/2000 exploratorios, no clínicos.
- El rating deriva de la misma tasa: el análisis por grupos es descriptivo.

Ética y privacidad

- Datos agregados por hospital: sin datos de pacientes. Licencia CC BY, con atribución.
- Se nombran hospitales: el resultado prioriza una revisión, no juzga calidad.
- Equidad: no premiar ni sancionar sin poder estadístico.
- La decisión final es de un auditor clínico.

Mitigación y escalabilidad

- Volumen fuera de los predictores (sin circularidad).
- CV + test independiente; árbol de profundidad 3.
- Lenguaje no causal en todas las conclusiones.
- Código público, semilla 42, Colab o local.
- Se actualiza con cada CSV anual y se extiende a otros indicadores AHRQ.

Conclusiones y recomendaciones

El trabajo no reemplaza el indicador: delimita qué puede afirmarse con estos datos y dónde hace falta información adicional.

Resultado más consistente

El volumen, utilizado de manera aislada, no predice la tasa. La cúpula tampoco se sostuvo.

Aporte propio

La persistencia no mide tamaño: mide si un desempeño se repite en el tiempo.

Bajo volumen

Un denominador pequeño produce mayor volatilidad: la tasa anual pierde información.

Recomendaciones

- Bajo volumen: evaluar un promedio móvil de tres años.
- Volumen medio: criterio vigente + seguimiento temporal.
- Alto volumen: sumar urgencias, oncología e inmunosupresión.

Próximos pasos

- Estudiar el case-mix con variables clínicas adicionales.
- Comparar formalmente la tasa trienal con la anual.
- Sumar años nuevos para ver si la persistencia se sostiene.

Cierre: yo había armado el índice de persistencia pensando que iba a pesar fuerte. No pesó como esperaba, y está bien que el análisis lo muestre. No forcé el resultado para defender la variable que había creado.

Anexo A · Diccionario de datos

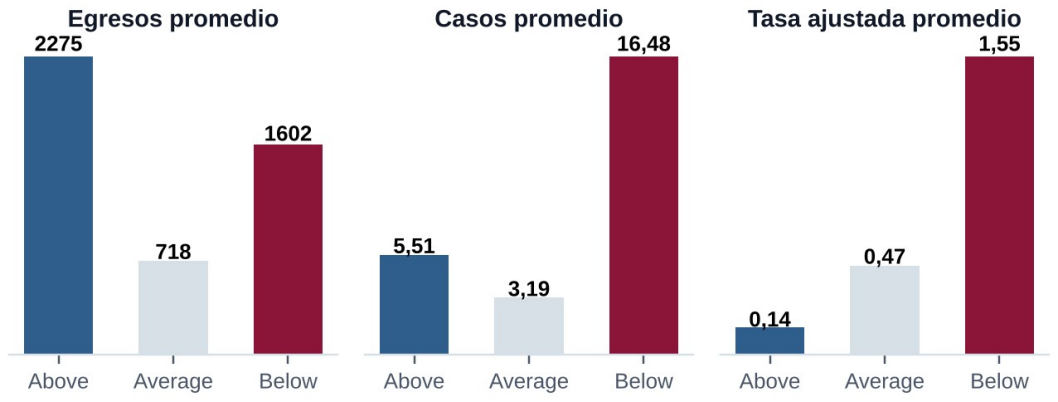
Las 10 variables del CSV original y su tratamiento.

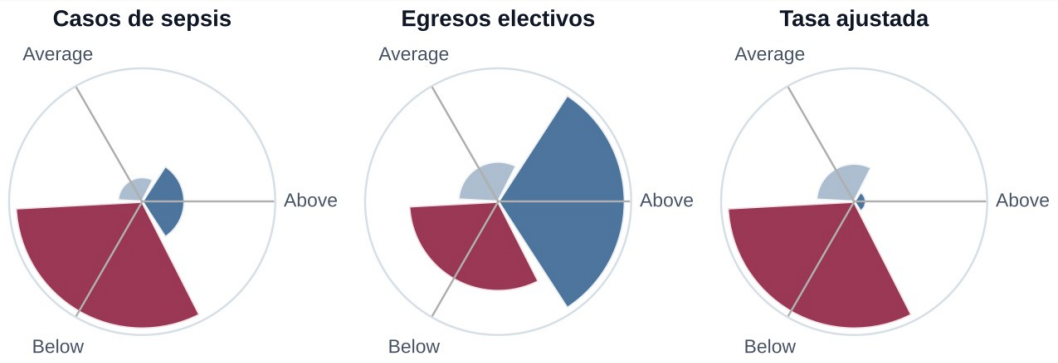
Variable	Tipo	Descripción y tratamiento
Year	Entero	Año del registro (2019–2023)
County	Nominal	Condado; STATEWIDE = agregado estatal (excluido)
OSHPDID	Identificador	Código único del hospital
Hospital Name	Nominal	Nombre del hospital
Postoperative Sepsis Cases	Discreta	Casos de sepsis posoperatoria (numerador)
Elective Surgical Discharges	Discreta	Egresos quirúrgicos electivos (denominador)
Risk-adjusted Postoperative Sepsis Rate	Continua	Tasa ajustada por riesgo, por 100 egresos
Risk-adjusted Performance Rating	Ordinal	Above · Average · Below Average
Longitude · Latitude	Continua	Texto convertido a numérico

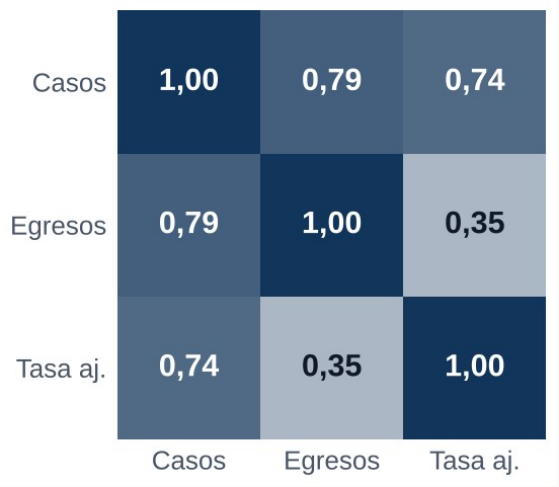
Variables derivadas: below_years, above_years, grupo de persistencia, volumen y tasa promedio, casos acumulados, segmento de volumen, log(volumen).

Anexo B · EDA complementario

Las categorías oficiales describen grupos; no validan el indicador de forma independiente.





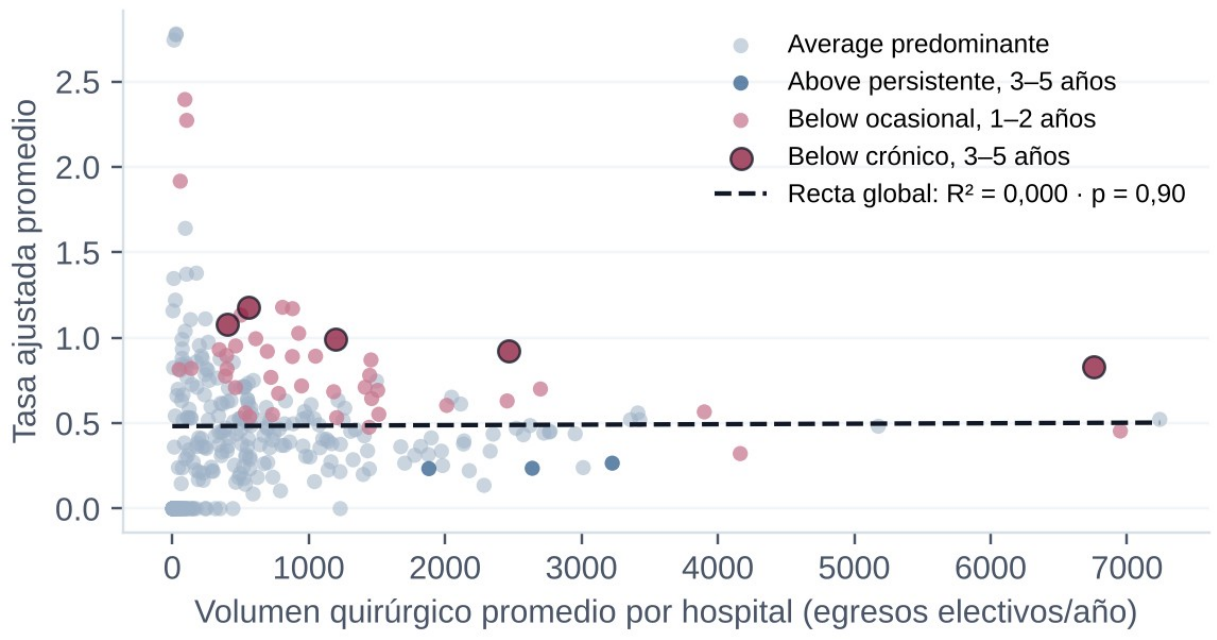


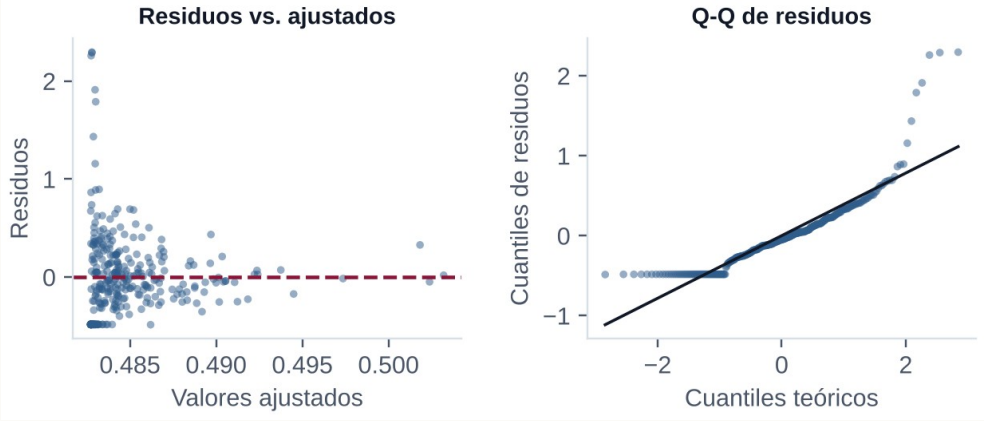
Above Average opera más (2.275 egresos) y tiene menos casos (5,51) que **Below Average** (1.602 y 16,48).

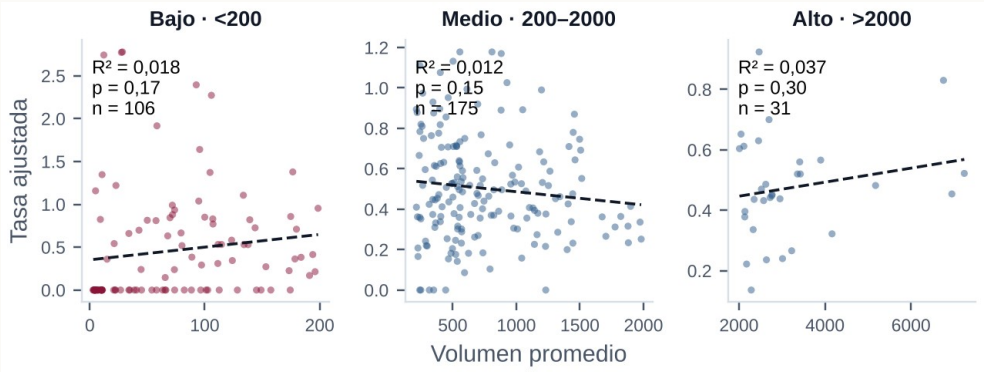
La rosa de Nightingale retoma el gráfico con el que Florence Nightingale comunicaba la mortalidad hospitalaria a quienes no leían tablas.

Anexo C · Diagnóstico de la regresión

Recta global, supuestos y regresión por segmento de volumen.



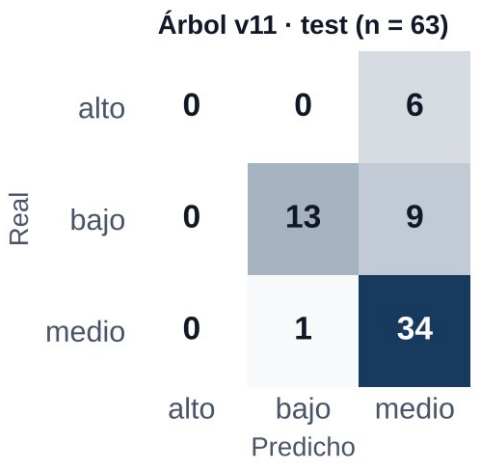




Residuos con dispersión desigual (heterocedasticidad) y colas fuera de la normal: una sola recta no describe hospitales tan distintos.

Anexo D · Clasificación complementaria

Árbol v11 y estabilidad por fold de todos los modelos.



Modelo	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Baseline	0,333	0,333	0,333	0,333	0,333
Regresión logística	0,517	0,444	0,594	0,446	0,522
Árbol v11	0,557	0,492	0,483	0,498	0,537
Árbol balanceado	**0,639**	**0,584**	**0,621**	**0,637**	**0,457**
Random Forest	0,701	0,629	0,594	0,590	0,459
XGBoost	0,674	0,625	0,644	0,494	0,513

Árbol v11: tasa 90 %, años Above 10 %, años Below 0 %. Recall del segmento alto = 0.

Balanced accuracy por fold (CV estratificada, semilla 42). Todos los modelos superan al baseline en todos los folds.

Anexo E · Hospitales de referencia y reproducibilidad

Casos extremos del índice de persistencia y cómo ejecutar el análisis.

Hospital	Grupo	Egresos/año	Tasa	Casos
Cedars-Sinai Medical Center	Below · 5 años	6.756	0,83	329
Alta Bates Summit Medical Center	Below · 4 años	1.198	0,99	59
Scripps Mercy Hospital	Below · 3 años	2.468	0,92	70
Dominican Hospital	Below · 3 años	556	1,18	35
Sutter Solano Medical Center	Below · 3 años	402	1,08	16
Kaiser Foundation Hospital Oakland/Richmond	Above · 4 años	2.639	0,24	47
Loma Linda University Medical Center	Above · 3 años	3.226	0,27	53
Kaiser Foundation Hospital Sacramento	Above · 3 años	1.881	0,23	25

Reproducibilidad

Colab: [agregar enlace]

GitHub: [agregar enlace]

El CSV 2019-2023-postoperative-sepsis-rates.csv va junto al notebook o en la raíz de Drive.

pandas, scikit-learn, XGBoost, SciPy; semilla 42.